


PreEntrega Módulo 3

Implementación de Memoria y Resumen Agéntico
Ingrid Ledesma | Septiembre 2026

Arquitectura del Workflow en n8n

Captura del lienzo completo del workflow **entregable_3_memory_manager_worker**. El flujo implementa persistencia híbrida: lectura de contexto desde Airtable, clasificación con AI Agent, despacho a workers, y escritura del resumen consolidado de vuelta a la base de datos.



Flujo del circuito:

#	Nodo	Funcion
1	When chat message received	Trigger de entrada (sessionId + chatInput)
2	Lectura Airtable	Search Records filtrado por Session_ID
3	If / Contexto rec. o nuevo	Bifurcación: usuario existente vs nuevo
4	AI Agent + Simple Memory	Clasificación de intenciones (JSON)
5	Contrato	Parseo JSON y armado del objeto unificado
6	Switch / Workers	Enrutamiento a workers especializados
7	Respuesta de workers	Normalización de la salida
8	Hay varios mensajes?	Si >5 msg → LLM Chain de summarization
9	Basic LLM Chain	Compresión a JSON estructurado
10	Guardar resumen/conv.	Upsert a Airtable (2 nodos)
11	Respuesta al cliente	Devolución final al chat

Prompt de Summarization (Basic LLM Chain)

El nodo **Basic LLM Chain** se activa cuando la conversación supera los 5 intercambios (controlado por **Hay varios mensajes?**). Comprime el historial acumulado en un JSON estructurado para optimizar la ventana de contexto.

System Prompt:

Sos un compresor de contexto para un sistema de atención al cliente.
Recibís el historial acumulado de un caso y devolvés un resumen mínimo.

Devolvés ÚNICAMENTE un JSON válido, sin markdown, sin explicaciones:

```
{
  "asunto_principal": "una frase con el motivo del contacto",
  "puntos_clave": ["dato 1", "dato 2"],
  "accion_requerida": "la acción concreta pendiente"
}
```

Reglas:

- Máximo 5 elementos en puntos_clave.
- No incluyas saludos, cortesías ni texto conversacional.
- No incluyas HTML, logs, IDs técnicos ni transcripciones completas.
- Si un dato ya figuraba en el historial, conservalo.

User Prompt:

Historial acumulado del caso:
{{ \$('Contrato').first().json.ctx_resumen }}

Última interacción:

Agente: {{ \$('Respuesta de workers').first().json.output }}

Configuración del modelo:

Parametro	Valor
Modelo	Groq - openai/gpt-oss-20b
Max Tokens	400
Activacion	ctx_mensajes > 5
Salida esperada	JSON: asunto_principal, puntos_clave, accion_requerida

Lógica de persistencia: El JSON resultante se guarda en el campo Resumen de la conversación de Airtable mediante el nodo **Guardar resumen comprimido** (upsert, matching por ID de sesión o usuario). Así, la próxima vez que el usuario escriba, el agente recupera un contexto limpio y compacto en lugar del historial crudo completo.

Esquema de Datos - Airtable

Base: **Memoria del Agente (renovadas)** · Tabla: **Memoria del Agente** · Operaciones: Search Records (lectura) / Upsert (escritura)

Esquema de columnas:

Columna	Tipo	Descripción	Ejemplo
ID de sesión o usuario	Single line text	Clave primaria. Filtra en Search y matching en Upsert.	58478039c895 ...
Fecha de última actualización	Last modified (auto)	Timestamp automático de Airtable. No se escribe desde n8n.	2026-09-23T14:30Z
Resumen de la conversación	Long text	Historial: append crudo (<5 msg) o JSON comprimido (>5 msg).	{"asunto_principal":...}
Estado del proceso	Single select	Estado del caso: En proceso, Pendiente, Resuelto, Escalado, etc.	En proceso
Datos clave	Long text	Datos del cliente (nombre, email, producto). Se inyecta al system prompt.	Claudia correo@... Zuri
cantidad de mensajes	Number	Contador de intercambios. Controla activación del LLM Chain (umbral: >5).	7
Próximo paso	Single line text	Acción pendiente para seguimiento. Campo opcional.	-
Responsable asignado	Single line text	Operador humano asignado si fue escalado. Opcional.	-
Fuente de interacción	Single select	Canal de origen: Web, Chat web, Email, Telefono, App, Otro.	Chat web
Nivel de prioridad	Single select	Prioridad del caso: Alta, Media, Baja.	Media

Circuito de persistencia:

Lectura: Trigger → Lectura Airtable (Search by Session_ID) → IF (existe?) → Contexto recuperado / Contexto nuevo

Escritura (<5 msg): Guardar conv. cruda → append de "Cliente: ... Agente: ..." al campo Resumen. Incrementa contador +1.

Escritura (>5 msg): LLM Chain comprime a JSON → Guardar resumen comprimido sobrescribe Resumen con JSON limpio. Resetea el contador a 0.

Matching: Ambas escrituras usan Upsert con matching por ID de sesión o usuario (crea si no existe, actualiza si existe).