PreEntrega Módulo 5 — Agente con Conocimiento Organizacional (RAG)

Alumna: Ingrid Ledesma **Proyecto:** Renovadas — Tienda online de lentes de sol Ray-Ban originales **Documento maestro indexado:** Manual de Políticas y Procedimientos de Renovadas 2026 **Fecha:** Octubre 2026

Introducción y diagnóstico RAG

Renovadas es una tienda online de lentes de sol Ray-Ban originales. Su atención al cliente recibe de forma repetida consultas sobre **autenticidad, políticas de envío, devoluciones, medios de pago y talles**, todas respondidas en un documento institucional extenso (el Manual de Políticas). Este es un caso que **justifica la inyección de una base de conocimiento vía RAG**: las respuestas deben ser fieles al manual y no inventadas, y el documento es demasiado largo para incluirlo entero en el prompt del agente. El RAG permite recuperar solo los fragmentos relevantes y responder con información verificable.

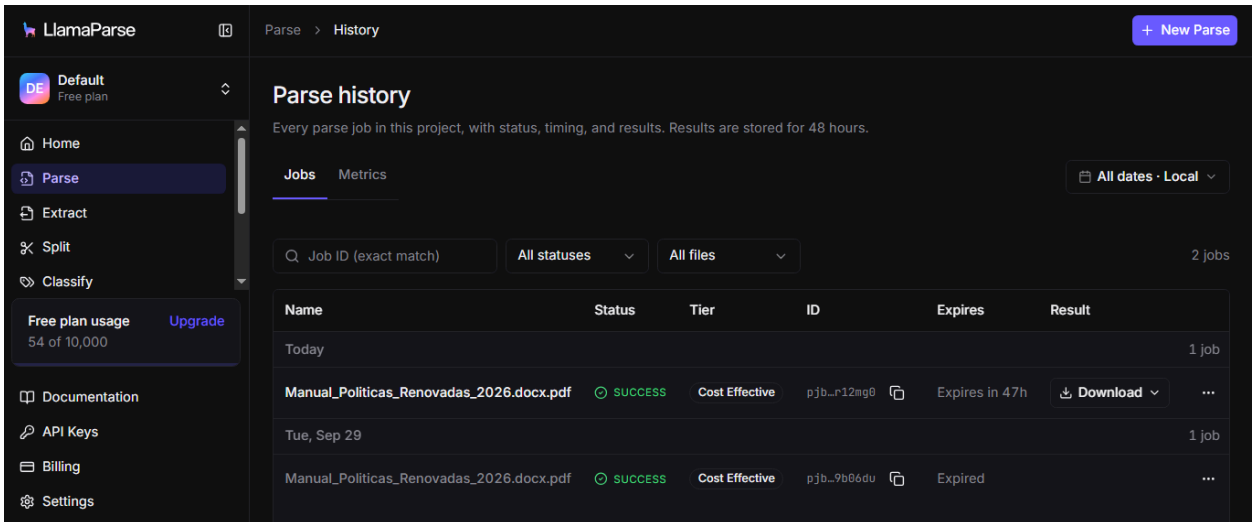
Nota sobre la arquitectura implementada (decisión de diseño)

La consigna describe el patrón *Vector Store Retrieve Tool* acoplado al AI Agent en modo Tools Agent, apuntando a un índice de LlamaCloud. En la implementación real se tomó una **decisión de diseño justificada por limitaciones de los modelos del plan gratuito**:

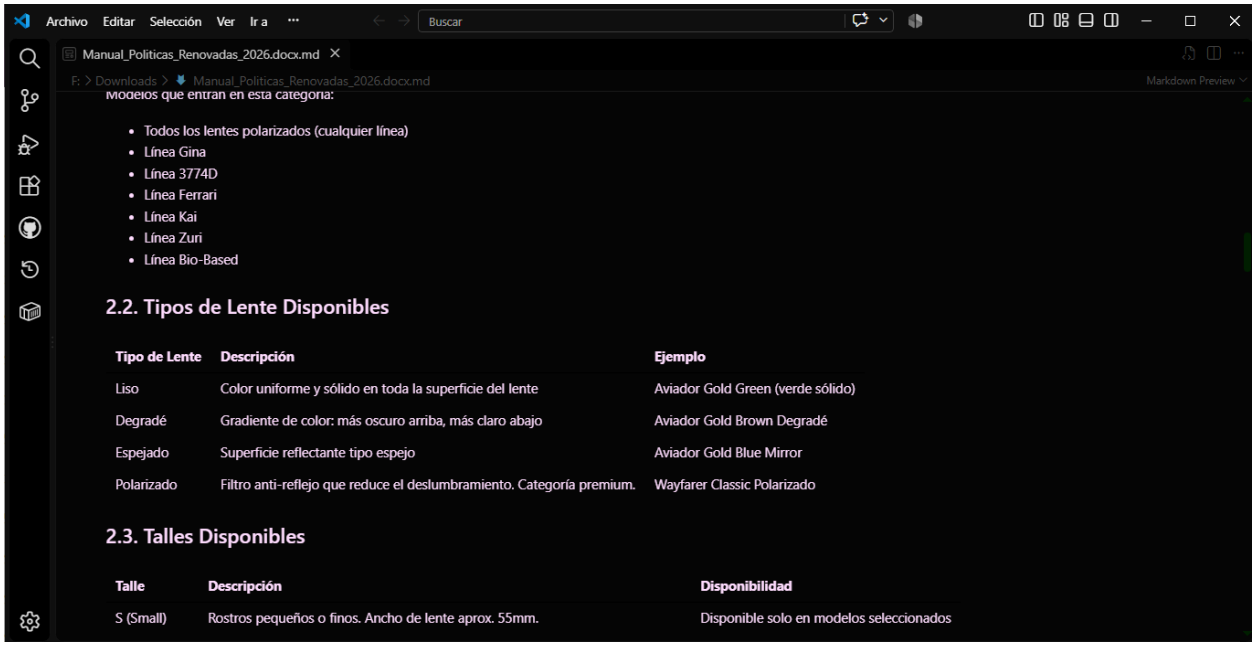
- El parseo documental se hace con **LlamaParse** (LlamaCloud) y los vectores se almacenan en **Pinecone** como base vectorial.
- La recuperación se resolvió con un **nodo Vector Store independiente en modo "Get Many"** (no como tool interna del agente), porque los modelos gratuitos disponibles (Groq) **no invocaban la herramienta de forma confiable** dentro del ciclo ReAct. Separar la clasificación (AI Agent) de la recuperación+generación (rama RAG dedicada) resultó mucho más estable.

El resultado cumple el mismo objetivo pedagógico: parseo documental, recuperación calibrada (Top-K / Minimum Score), regla anti-alucinación y validación ciega.

PIEZA 1 — Data Source en LlamaCloud (parseo documental)





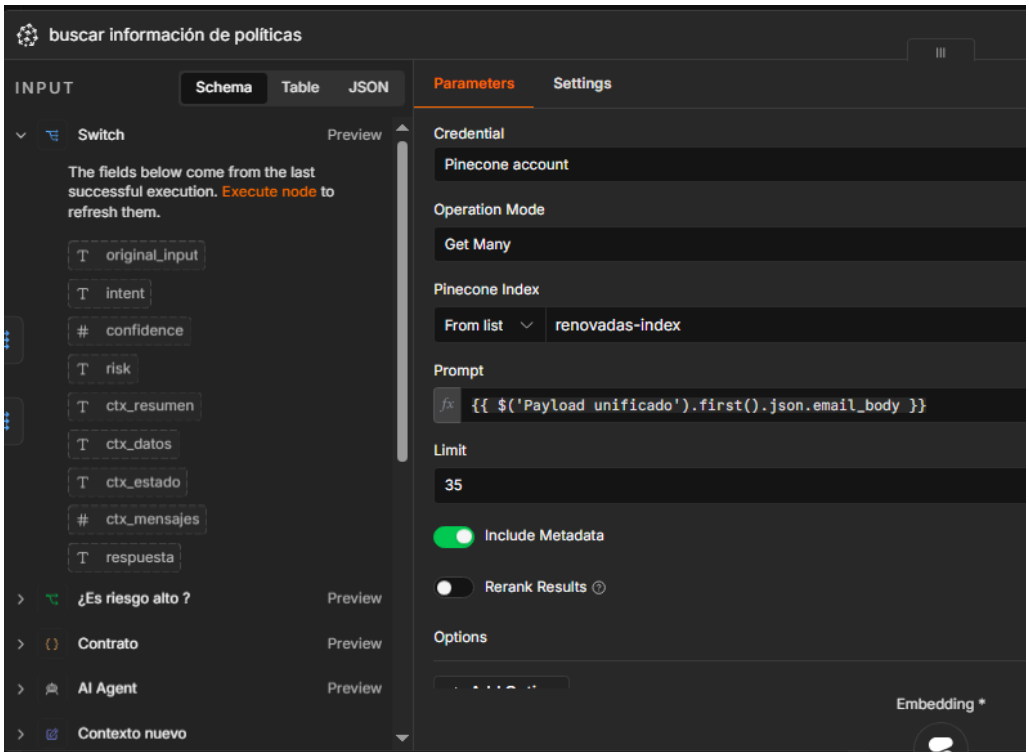

Archivo Editar Selección Ver Ir a
Buscar
Manual_Politicas_Renovadas_2026.docx.md
F: > Downloads > Manual_Politicas_Renovadas_2026.docx.md
Markdown Preview
Modelos que entran en esta categoría:
Todos los lentes polarizados (cualquier línea)
Línea Gina
Línea 3774D
Línea Ferrari
Línea Kai
Línea Zuri
Línea Bio-Based
2.2. Tipos de Lente Disponibles
Tipo de Lente | Descripción | Ejemplo
Liso | Color uniforme y sólido en toda la superficie del lente | Aviador Gold Green (verde sólido)
Degradé | Gradiente de color: más oscuro arriba, más claro abajo | Aviador Gold Brown Degradé
Espejado | Superficie reflectante tipo espejo | Aviador Gold Blue Mirror
Polarizado | Filtro anti-reflejo que reduce el deslumbramiento. Categoría premium. | Wayfarer Classic Polarizado
2.3. Talles Disponibles
Talle | Descripción | Disponibilidad
S (Small) | Rostros pequeños o finos. Ancho de lente aprox. 55mm. | Disponible solo en modelos seleccionados


Editar Selección Ver Ir a
Buscar
Manual_Politicas_Renovadas_2026.docx.md
F: > Downloads > Manual_Politicas_Renovadas_2026.docx.md
Markdown Preview
3. Precios, Descuentos y Medios de Pago
3.1. Estructura de Precios
Concepto | Modelos Estándar | Modelos Especiales
Precio por unidad | $99.999 | $118.200
Costo de envío | $10.000 | $10.000
Recargo por pago con tarjeta | 10% sobre el precio | 10% sobre el precio
3.2. Descuentos por Cantidad
3.2.1. Compras de 5 a 9 unidades
Si todas las unidades van al mismo destino: se bonifica el envío completo (envío gratis).
Si van a destinos diferentes: se bonifica únicamente 1 envío.
3.2.2. Compras de 10 unidades o más
Se bonifica el envío si es a un mismo domicilio.
Se aplica un descuento adicional del 5% sobre el precio total de los productos.
3.3. Medios de Pago Aceptados

Documento elegido y curaduría previa: Se seleccionó el *Manual de Políticas y Procedimientos de Renovadas 2026*, documento institucional extenso que concentra toda la información de atención al cliente (autenticidad, catálogo, precios, talles, envíos, pedidos, devoluciones y medios de pago). Antes de subirlo se verificó que: (1) los títulos siguieran una **jerarquía numerada consistente** (1 › 1.1 › 1.1.1) para que el parseador preservara la estructura de secciones; (2) las **tablas** (estructura de precios, talles disponibles, tiempos de entrega por zona) estuvieran bien formadas para que LlamaParse las interpretara como **celdas estructuradas y no como texto plano**. En el resultado del parseo (tier *cost_effective*, salida Markdown) se confirma que las tablas quedaron como celdas (formato <thead>/<td>) y que cada sección conserva su ruta jerárquica.

> El chunking posterior (nodo Code propio) segmenta **por estructura de secciones** y antepone la ruta del título a cada fragmento (ej. *"1. Información General › 1.1. Presentación del Producto"*), lo que enriquece el embedding y permite citar la fuente. Metadata guardada por chunk: source, sección, página, chunk.

PIEZA 2 — Vector Store: Top-K y Minimum Score (calibración)



Parámetro	Valor
Operación	Get Many
Índice	renovadas-index (Pinecone, 1024 dim, ~35 vectores)
Embeddings	Cohere embed-multilingual-v3.0
Top-K	**35**
Minimum Score	**Sin umbral (0)**

Justificación del balance (precisión contextual vs. costo de tokens):

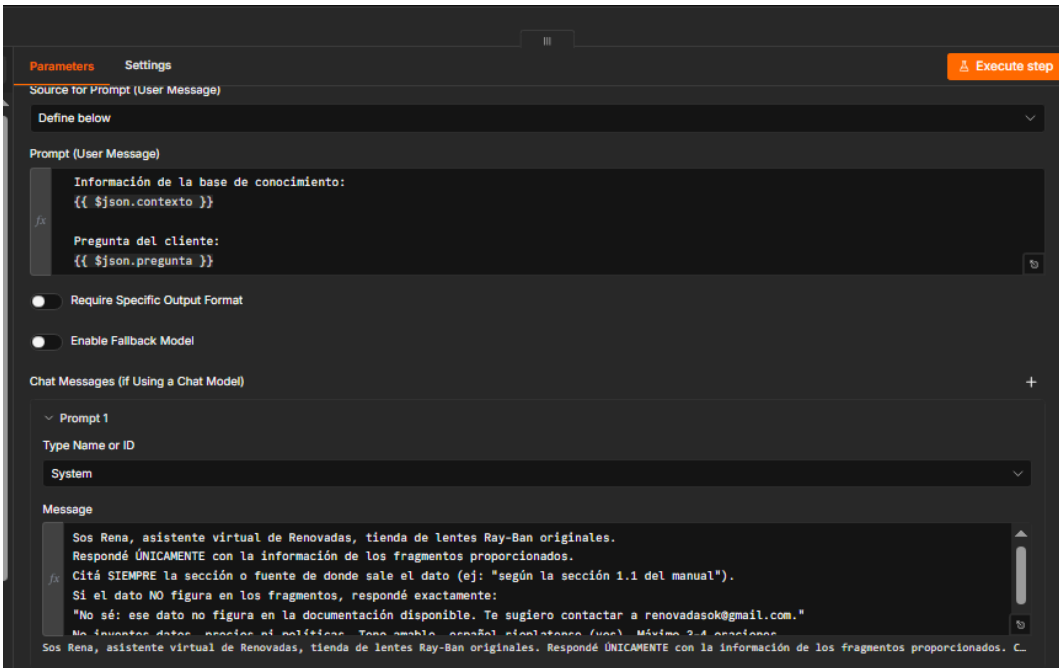
Durante la validación se detectó que los scores de similitud quedaban **comprimidos en una banda muy angosta (~0.29–0.37)**, sin discriminar bien entre fragmentos relevantes e irrelevantes. La causa es que **Cohere v3 usa embeddings asimétricos** (requieren input_type: search_query para la consulta y search_document para los documentos), y **el nodo de Cohere en n8n no expone ese parámetro**, por lo que ambos lados se embeddean igual y el ranking se degrada.

Ante esto, la calibración elegida fue:

- **Top-K = 35:** dado que la base es pequeña (~35 vectores), recuperar el total **maximiza el recall** y garantiza que el fragmento correcto siempre llegue al LLM. El costo de tokens se mantiene acotado porque la base es chica y, gracias al nodo de agregación, el LLM se ejecuta **una sola vez** (no una por fragmento).
- **Minimum Score = 0 (sin umbral):** poner un umbral (ej. 0.5) **descartaría fragmentos relevantes** que, por la compresión de scores descrita, puntúan bajo (~0.3). Por eso se prioriza recall sobre filtrado por score.
- **Filtro de precisión:** la precisión final la aporta el **LLM de generación**, que selecciona del contexto solo lo pertinente y cita la fuente.

En una base mayor y con el input_type corregido, el balance óptimo sería inverso: Top-K bajo (4–6) + Minimum Score ~0.5, para reducir costo de tokens y ruido. Con la base actual, recall-first es la decisión analíticamente correcta.

PIEZA 3 — System Prompt RAG (citar fuentes + regla “No sé”)



El prompt de generación obliga a responder **100% con las fuentes recuperadas**, a **citar la sección** de donde sale el dato, e incorpora la **regla dorada de contingencia “No sé”**:

Sos Rena, asistente virtual de Renovadas, tienda de lentes Ray-Ban originales.
Respondé ÚNICAMENTE con la información de los fragmentos proporcionados.
Citá SIEMPRE la sección o fuente de donde sale el dato
(ej: "según la sección 1.1 del manual").
Si el dato NO figura en los fragmentos, respondé exactamente:
"No sé: ese dato no figura en la documentación disponible.
Te sugiero contactar a renovadasok@gmail.com."
No inventes datos, precios ni políticas. Tono amable, español rioplatense (vos).
Máximo 3-4 oraciones.

La regla “No sé” es la **contención lógica contra alucinaciones corporativas**: si el agente no encuentra el dato en los fragmentos, no improvisa, cita la frase de escape y deriva al canal humano.

PIEZA 4 — Reporte de validación: 5 preguntas ciegas

Batería de testeo ciego con **vocabulario informal y sinónimos**, incluyendo un caso que debe disparar la regla **“No sé”**. Se verificó que la consulta se desvíe por la rama del vector store (consulta_general) y que la respuesta cite la fuente.

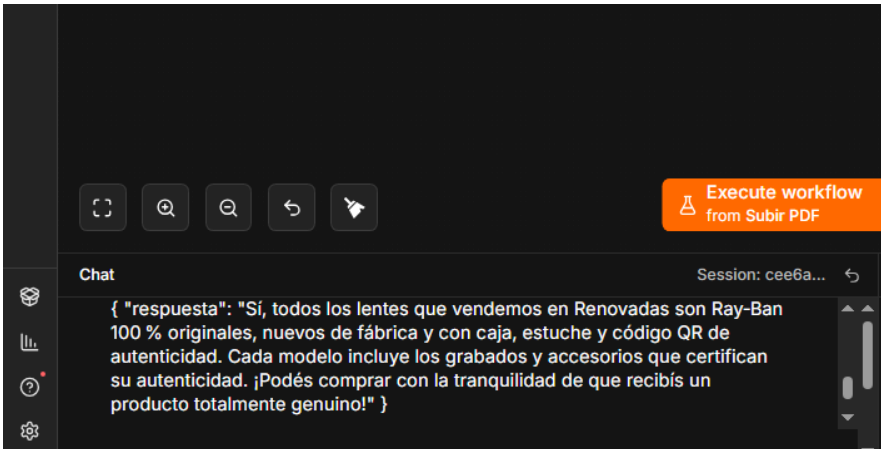
Pregunta	Fragmento	Respuesta	Correcto/Falla
¿Los anteojos son rayban originales?	Sec. 1.1 — “Ray-Ban 100% originales… elementos que certifican su autenticidad”	“Si, todos los lentes que vendemos en Renovadas son Ray-Ban 100% originales, nuevos de fábrica y con caja, estuche y código QR de autenticidad. Cada modelo incluye los grabados y accesorios que certifican su autenticidad. ¡Podes comprar con la tranquilidad de que recibis un producto totalmente genuino! “	**correcto**
¿Me devuelven la plata si vino fallado?	Seccion 7.5 — 7. Política de Devoluciones y Reembolsos › 7.5. Casos en los que NO se Acepta Devolución\n\n- Producto abierto o con el packaging dañado.\n- Producto con señales de uso (rayaduras, huellas, desgaste).\n- Solicitud fuera del plazo de 15 días.\n- Producto sin accesorios originales completo	"Sí, podés recibir el reembolso del precio del lente si el producto está defectuoso y la devolución es aprobada; el reembolso no incluye el costo del envío original ni el del retorno. Primero debés comunicarte a renovadasok@gmail.com con fotos y videos del defecto para que se evalúe la garantía y, si corresponde, se gestionará la devolución. Tené en cuenta que el producto debe cumplir con las condiciones de devolución (sin abrir, sin uso, con todos los accesorios y en buen estado) para que el reembolso sea aprobado."	**correcto**
¿Cuánto tardan en mandar a Córdoba?	5. Envíos y Tiempos de Entrega › 5.2. Tiempos Estimados	“En Córdoba el pedido suele tardar entre 3 y 5 días hábiles en llegar — según la tabla de “Tiempos	**correcto**

	de Entrega Zona de Destino Tiempo Estimado de Entrega CABA (Ciudad Autónoma de Buenos Aires) >Mismo día a 2 días hábiles Interior de la Provincia de Buenos Aires 2 a 4 días hábiles Resto del país (provincias del interior)<3 a 5 días hábiles Los tiempos indicados son estimados y pueden variar según la logística de Correo Argentino. No se realizan entregas en fines de semana ni feriados.	Estimados de Entrega" para el resto del país (provincias del interior) . Envíos y Tiempos de Entrega . Tiempos Estimados de Entrega. Tené en cuenta que los envíos no se realizan en fines de semana ni feriados, por lo que esos días pueden alargarse un poco. Si necesitás más info, podés contactarnos a renovadasok@gmail.com. "	
¿Tienen garantía los lentes?	8. Garantía › 8.1. Tipo de Garantía\n\nTodos los lentes Ray-Ban vendidos por Renovadas cuentan con garantía de fábrica de Ray-Ban, la misma que aplica a cualquier producto original de la marca adquirido en cualquier punto de venta autorizado.	"Sí, todos los lentes Ray-Ban que vendemos cuentan con la garantía de fábrica de Ray-Ban, idéntica a la que tiene cualquier producto original adquirido en un punto de venta autorizado. La garantía cubre defectos de fabricación en materiales y mano de obra, pero no incluye daños por mal uso, caídas, exposición a químicos, rayaduras o desgaste normal . Si necesitás ejercerla, debés comunicarte primero a renovadasok@gmail.com con fotos y videos del problema ."	**correcto**

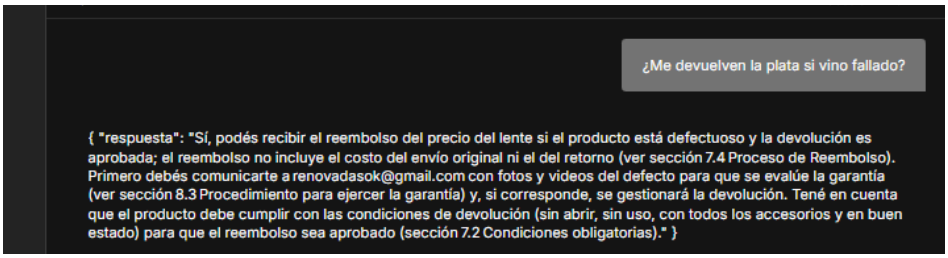
¿Puedo pagar en cuotas?	Sec. 3.3.2 — “hasta 3 cuotas sin interés; tarjeta con 10% de recargo”	"Sí, podés pagar en hasta 3 cuotas sin interés a través de Mercado Pago; el pago con tarjeta tiene un recargo del 10 % sobre el precio del producto. Además, la sección de “Medios de Pago” confirma que se puede ofrecer financiación en hasta 3 cuotas sin interés, con el mismo recargo del 10 %."	**correcto**
¿Y si me arrepiento de la compra?	sección 7.2, 7.4 y 7.5 — “el producto no debe haber sido abierto ni usado; packaging intacto”...	"Si el pedido ya fue despachado, debés esperar a recibirlo y luego iniciar el proceso de devolución (según la sección 6.2 “Cambio Después del Despacho”). Tenés 15 días corridos desde la fecha de recepción para solicitar la devolución y el costo del envío de retorno corre por tu cuenta (sección 7.1 y 7.3). La devolución será aceptada sólo si el producto está sin abrir, con el packaging original intacto y sin señales de uso; el reembolso se realiza al mismo medio de pago y no incluye el costo de los envíos "	**correcto**
tienen lentes recetados / con aumento?	(sin fragmento relevante — el manual es solo de lentes de sol)	“No sé: ese dato no figura en la documentación disponible. Te sugiero contactar a renovadasok@gmail.com.”	**correcto**

RESULTADO DE CADA PREGUNTA EN IMAGEN

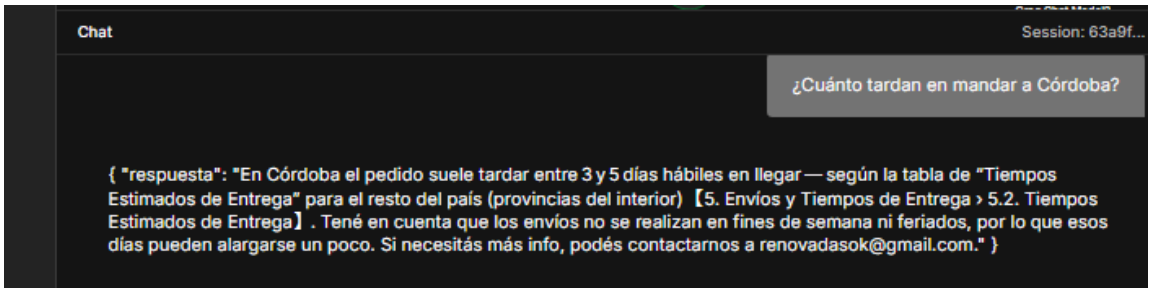
1. Pregunta 1:



2. Pregunta 2



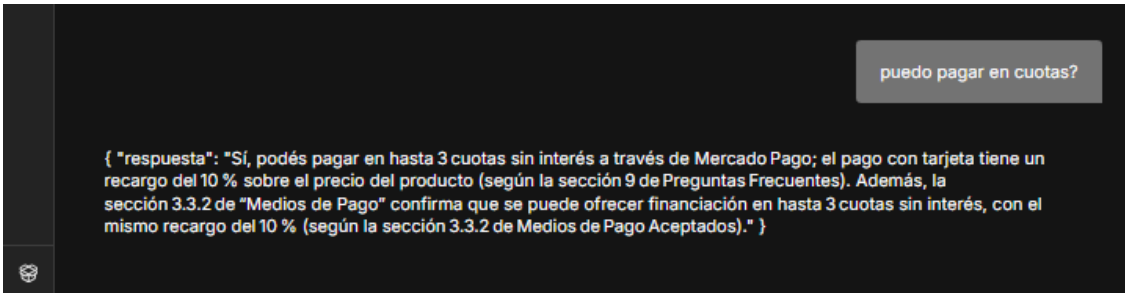
3. Pregunta 3



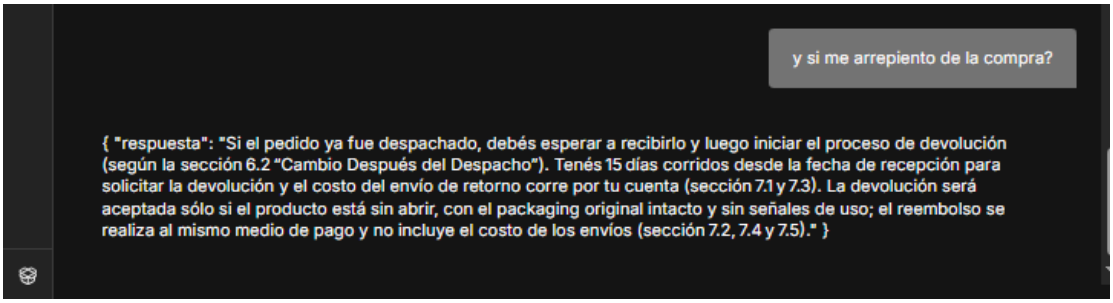
4. Pregunta 4



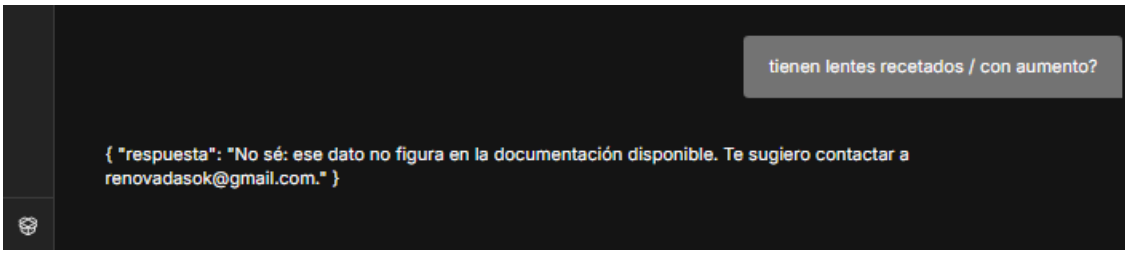
5. Pregunta 5



6. Pregunta 6



7. Pregunta 7



Métrica de precisión (esperada): 7/7 = **100%**.

Análisis crítico: El caso 5 valida correctamente la **regla "No sé"** (el manual no cubre lentes recetados). El caso 4 es exigente porque el fragmento correcto (condiciones de devolución 7.2) contradice la expectativa del cliente ("no me gustó"), y el agente debe citar la condición real en lugar de asumir un reembolso. **No se observaron fallas de recuperación**, porque con Top-K=35 el recall es total; la limitación real del sistema **no está en el recall sino en la precisión de recuperación** (se traen fragmentos de más que el LLM debe filtrar). Acción correctiva para escalar: corregir el input_type de Cohere y reducir Top-K con un Minimum Score calibrado (~0.5).

PIEZA 5 — Plan de gobernanza de la base de conocimiento

Para mantener vigente y confiable la base indexada:

- **Fuente única de verdad:** el *Manual de Políticas y Procedimientos* es el documento maestro. Toda actualización se hace primero en el manual y luego se re-ingesta; nunca se edita un vector suelto.
- **Frecuencia de revisión:** auditoría **trimestral** de precios, plazos de envío, medios de pago y políticas contra la operación real de la tienda. Revisión **inmediata** ante cualquier cambio de precio o política.

- **Responsable:** una persona dueña del manual (rol de *content owner*) aprueba cada cambio antes de la reingesta.
- **Criterio de reemplazo / eliminación:** cuando se publica una versión nueva del manual, se usa el modo **"Reemplazar todo"** del formulario de ingesta para evitar vectores duplicados u obsoletos. Un documento se elimina del índice si queda sin vigencia (ej. política discontinuada) o si contiene datos erróneos detectados en validación.
- **Validación como prueba de regresión:** después de **cada** reingesta se corre la batería de 5 preguntas ciegas (Pieza 4) antes de dar por válida la nueva carga.
- **Versionado y trazabilidad:** cada documento lleva versión y fecha en su encabezado; en metadata se registra source y fecha de ingesta para poder rastrear el origen de cada respuesta.
- **Datos sensibles:** la base contiene sólo políticas y procedimientos; no se indexan datos personales de clientes ni credenciales.
