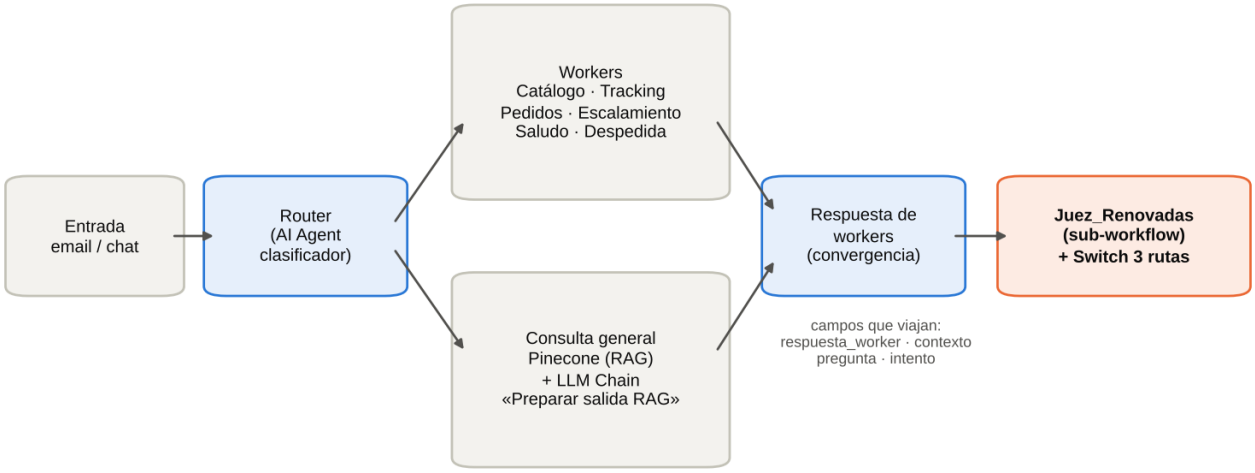
Checkpoint Módulo 8

Supervisor + Juez (AI-as-a-Judge) para el agente de atención al cliente de Renovadas

Ingrid Ledesma · Curso de automatización · 11/10/2026

Bloque 1 · Supervisor y rúbrica del Juez 60 %

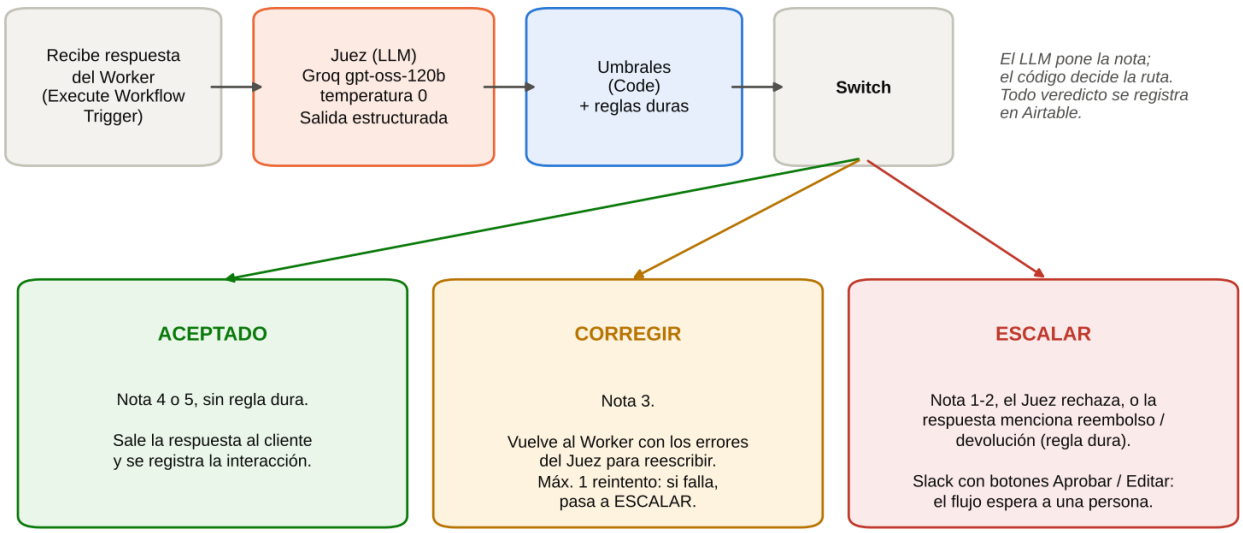
1.1 Arquitectura: todas las salidas pasan por el Juez



Todas las rutas (Workers y RAG) pasan por el mismo punto de convergencia antes del Juez: ninguna salida se escapa de la auditoría.

- **Un solo Juez, no cuatro copias.** Se implementó como sub-workflow (`Juez_Renovadas`) que se invoca con un nodo Execute Workflow; cambiar la rúbrica en un lugar actualiza a todos los Workers.
- **Punto de convergencia.** Los Workers y la ruta RAG (Pinecone + LLM Chain) desembocan en el nodo «Respuesta de workers», que normaliza los campos `respuesta_worker`, `contexto`, `pregunta` e `intento`. Así ninguna ruta se escapa de la auditoría.
- **El Juez pone la nota, el código decide la ruta.** Los umbrales (4 y 3), el máximo de 1 reintento y la regla dura de dinero viven en código auditable, no en el LLM.
- **Contexto que recibe el Juez.** La consigna lo menciona como «contexto recuperado de Airtable»; en este agente el contexto se recupera de la base vectorial (Pinecone, RAG) y es ese mismo texto el que recibió el Worker. El Juez recibe tres cosas: la pregunta original, ese contexto y la respuesta propuesta. Airtable se usa como repositorio de auditoría de los veredictos (sección 1.7).

1.2 Sub-workflow del Juez y Switch de tres rutas

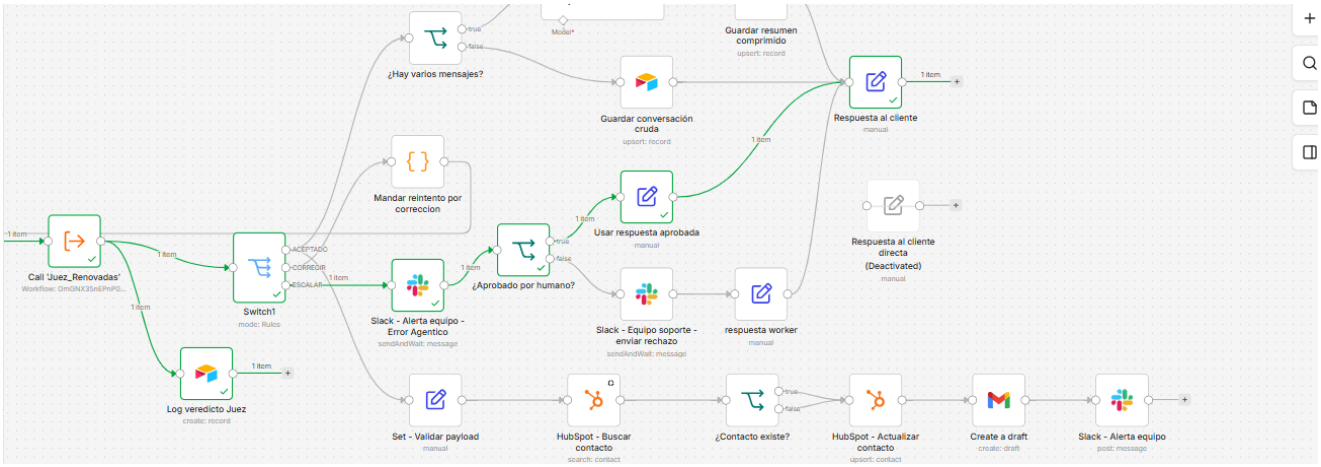


Ruta	Condición (decidida por código)	Acción	Caso observado en las pruebas
ACEPTADO	Nota 4 o 5 y sin regla dura.	Se entrega la respuesta al cliente y se guarda la conversación en Airtable (memoria del agente). Continúa el flujo de CRM: HubSpot, borrador de Gmail y aviso a Slack.	P1, P2, P4 y P5.
CORREGIR	Nota 3 (y `intento` = 0).	El nodo de código «Mandar reintento por correccion» arma el reintento con los errores del Juez (`errores_juez`) e `intento` = 1 y lo devuelve al Worker. Si el Juez vuelve a dar 3, el código lo pasa a ESCALAR: máximo 1 reintento.	No se activó en las 5 pruebas finales; se observó un 3/5 en una ejecución previa al ajuste de la rúbrica.
ESCALAR	Nota 1-2, veredicto RECHAZADO del Juez, o la respuesta menciona reembolso / devolución (regla dura).	Slack «Send and Wait for Response»: el flujo se pausa y publica pregunta, nota, errores y respuesta propuesta con botones **Aprobar** / **Editar**. Aprobar envía la respuesta del Worker; Editar abre un segundo mensaje de Slack donde una persona escribe la respuesta corregida, que es la que se envía.	P3 (devolución de producto roto): escalada por la regla dura de dinero (capturas 3 y 4).

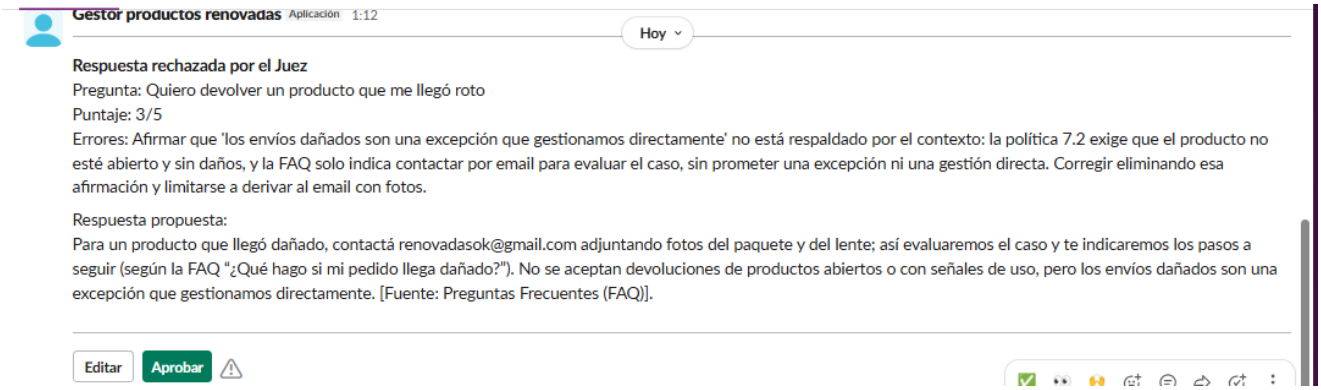
Nomenclatura. El Juez emite siempre uno de los tres valores del esquema (ACEPTADO, CORREGIR, RECHAZADO). El nodo «Umbrales» aplica los umbrales y las reglas duras y escribe el estado final que lee el Switch: el RECHAZADO del Juez pasa a llamarse **ESCALAR** (ruta humana). Las 5 corridas del Bloque 2 se registraron cuando esa ruta aún se llamaba RECHAZADO; el cambio de nombre no alteró la lógica.



Captura 1 · Sub-workflow `Juez_Renovadas` en n8n: Recibe la respuesta → nodo Juez (LLM con modelo Groq y Structured Output Parser «Formato veredicto») → nodo de código «Umbrales». Ejecución exitosa.



Captura 2 · Flujo principal: `Call 'Juez_Renovadas'` → `Switch1` con sus tres salidas (ACEPTADO / CORREGIR / ESCALAR). Ejecución de verificación: el veredicto salió por ESCALAR → Slack (Send and Wait) → «¿Aprobado por humano?» → respuesta al cliente. En paralelo, «Log veredicto Juez» registra el veredicto en Airtable (1 item).



Captura 3 · Ruta ESCALAR: mensaje en Slack con la pregunta, la nota del Juez (3/5), los errores detectados, la respuesta propuesta y los botones Aprobar / Editar. El flujo permanece en pausa hasta que una persona decide.

1.3 Rúbrica

Criterio	Pregunta que responde	Descuento
Exactitud factual	¿Menciona productos, precios, estados de pedido, plazos u otros datos que no están en el contexto que recibió el Worker?	-2
Coherencia con la intención	¿Contesta lo que el cliente preguntó?	-1
Tono y extensión	¿Es empática, profesional y concisa (máximo 5 líneas)?	-1
Accionabilidad	¿Le da al cliente un próximo paso claro?	-1

La nota arranca en 5 y se descuenta (mínimo 1). Casos especiales definidos en el prompt: si el dato realmente no está en el contexto y el Worker lo reconoce y deriva a `renovadasok@gmail.com`, no se descuenta; si lo consultado no se vende (por ejemplo, la tienda solo vende lentes Ray-Ban), una aclaración clara es correcta; si el contexto permitía aclararlo y el Worker respondió con un «No sé» genérico, se descuenta 1 por coherencia.

1.4 Prompt del Juez (transcripción)

System Message del nodo «Juez Renovadas» (agente LLM, modelo `openai/gpt-oss-120b` en Groq, temperatura 0):

Sos el Juez de calidad de Renovadas, una tienda online argentina de lentes de sol Ray-Ban originales (nuevos, de fábrica). Evaluás la respuesta de un Worker (agente especializado) que atiende consultas de clientes por email o chat.

No reescribís la respuesta: la calificás contra esta rúbrica, usando SOLO el contexto que recibió el Worker.

Vas a recibir tres cosas: la PREGUNTA DEL CLIENTE, el CONTEXTO QUE RECIBIÓ EL WORKER y la RESPUESTA DEL WORKER. Evaluá si la respuesta contesta la pregunta del cliente usando solo ese contexto.

RÚBRICA (puntaje de 1 a 5: arrancá en 5 y descontá; el mínimo es 1)
1. Exactitud factual (-2): ¿Menciona productos, precios, estados de pedido, plazos de entrega o datos que NO están en el contexto recibido? Si inventa cualquier dato, descontá 2.
2. Coherencia con la intención (-1): ¿La respuesta contesta lo que el cliente preguntó? Si preguntó por tracking y le habla del catálogo, descontá 1.
3. Tono y extensión (-1): ¿Es empática, profesional y concisa (máximo 5 líneas)? Si es fría, robótica o demasiado larga, descontá 1.
4. Accionabilidad (-1): ¿Le da al cliente un próximo paso claro? (ej: 'tu pedido llega el martes', 'te paso con un asesor', 'escribinos a renovadasok@gmail.com'). Si no hay próximo paso, descontá 1.

CASOS ESPECIALES
- Dato ausente del contexto: si la información realmente no está en el contexto y el Worker lo reconoce y deriva al cliente a renovadasok@gmail.com, es el comportamiento correcto. No descontés por exactitud ni por accionabilidad.
- Producto o servicio que la tienda no ofrece: si el contexto permite concluir que lo consultado no se vende (por ejemplo, la tienda solo vende lentes de sol Ray-Ban) y el Worker lo aclara con claridad, la respuesta es correcta.
- Oportunidad desaprovechada: si el contexto sí permitía responder o aclarar que no se ofrece, y el Worker contestó con un 'No sé' genérico, descontá 1 por coherencia con la intención.

ESTADO
- ACEPTADO: score 4 o 5, sin errores graves.
- CORREGIR: score 3, errores que se arreglan reescribiendo.
- RECHAZADO: score 1 o 2, o si la respuesta inventa datos que no están en el contexto, o si promete descuentos, reembolsos o beneficios que no figuran en el contexto.

REGLAS
- Primero listá los errores (cada uno en una línea: qué está mal y cómo corregirlo). Si no hay, lista vacía.
- Después escribí la justificación: 1 o 2 frases en español rioplatense.
- Al final el score (entero de 1 a 5).
- No premies respuestas largas: la concisión vale.

Mensaje de usuario (campo Text del mismo nodo; incluye la pregunta del cliente):

```
={{ 'PREGUNTA DEL CLIENTE:\n' + ($json.pregunta || '(no disponible)')
  + '\n\nCONTEXTO QUE RECIBIÓ EL WORKER:\n' + $json.contexto
  + '\n\nRESPUESTA DEL WORKER:\n' + JSON.stringify($json.respuesta_worker, null, 2) }}
```

1.5 Esquema JSON de salida (Structured Output Parser)

```
{
  "type": "object",
  "properties": {
    "errores": {
      "type": "array",
      "items": {
        "type": "string"
      },
      "description": "Lista de errores encontrados. Vacía si no hay."
    },
    "justificacion": {
      "type": "string",
      "description": "1-2 frases explicando el puntaje."
    },
    "exactitud_factual": {
      "type": "integer",
      "minimum": 1,
      "maximum": 5,
      "description": "Puntaje de exactitud factual de 1 a 5."
    },
    "estado_veredicto": {
      "type": "string",
      "enum": [
        "ACEPTADO",
        "CORREGIR",
        "RECHAZADO"
      ],
      "description": "Veredicto del Juez."
    }
  },
  "required": [
    "errores",
    "justificacion",
    "exactitud_factual",
    "estado_veredicto"
  ]
}
```

Campos que gobiernan el Switch: `exactitud_factual` (entero 1-5, nota global de la rúbrica) y `estado_veredicto` (ACEPTADO | CORREGIR | RECHAZADO). **Campos auxiliares:** `errores` y `justificacion`; no intervienen en la decisión, pero son la crítica que se reenvía al Worker en CORREGIR y el detalle que se muestra en Slack y se guarda en la auditoría. El esquema es obligatorio (los cuatro campos son `required`); el estado final que lee el Switch lo escribe el código (sección 1.6), por lo que la salida nunca es texto libre; sin JSON válido el nodo reintenta (hasta 3 veces).

1.6 Umbrales y reglas duras (nodo Code «Umbrales»)

```
const e = $('Recibe la respuesta').first().json;
const v = $input.first().json.output;
const r = e.respuesta_worker;

// REGLA DURA: si el borrador promete plata, decide una persona. Siempre.
const texto = typeof r === 'string' ? r : (r.borrador_mensaje || r.respuesta || '');
const ctx = (e.contexto || '').toLowerCase();
const siempre = /(reembols|devoluci|cr[eé]dito a favor)/i.test(texto);
const promo = (texto.match(/(descuento|bonificaci|gratis|sin cargo)/gi) || [])
  .some(p => !ctx.includes(p.toLowerCase()));  // promo solo cuenta si NO figura en el contexto
const prometeDinero = siempre || promo;

// Umbrales por código (no por LLM)
let estado = 'ESCALAR';                          // default: menos de 3
if (v.exactitud_factual >= 4) estado = 'ACEPTADO';   // 4 o 5 -> aprobado
else if (v.exactitud_factual >= 3) estado = 'CORREGIR'; // 3 -> corregir

// Sobreescrituras
if (v.estado_veredicto === 'RECHAZADO') estado = 'ESCALAR';  // el Juez rechaza
if (prometeDinero) estado = 'ESCALAR';                       // regla dura
if (estado === 'CORREGIR' && e.intento >= 1) estado = 'ESCALAR'; // max. 1 reintento

const motivo = prometeDinero ? 'el borrador promete dinero al cliente (regla dura)' : '';
return [{ json: { ...e,
  exactitud_factual: v.exactitud_factual,
  estado_veredicto: estado,          // lo lee el Switch
  errores: v.errores,
  justificacion: v.justificacion,
  regla_dura: motivo } }];
```

Los términos de reembolso y devolución siempre escalan a una persona; los de promoción (descuento, envío gratis) solo escalan cuando no figuran en el contexto, para no rechazar respuestas correctas que citan una política real.

1.7 Registro del veredicto en repositorio externo (auditoría)

Cada veredicto se guarda en Airtable (base `Veredictos_Juez`) mediante el nodo «Log veredicto Juez», conectado en paralelo a la salida del Juez, antes del Switch: se registran las tres rutas, también las que no terminan en una respuesta automática. Campos: `Pregunta`, `Puntaje`, `estado`, `Errores`, `Justificacion`, `Respuesta`, `Intento`, `Regla_dura`.

	Pregunta	Puntaje	estado	Errores	Justificacion	Respuesta	Intento	Fecha	Regla_dura
1	Quiero devolver un produc...	3,0	ESCALAR	Afirmar que los envíos dañ...	La respuesta deriva bien al ...	Para un producto que...	0,0		el borrador promete diner...

Captura 4 · Registro de auditoría en Airtable de la misma ejecución de la captura 3: `Puntaje` 3, `estado` ESCALAR y motivo en `Regla_dura` (el borrador promete dinero).

1.8 Evidencia de ejecución (Arquitectura B)

P	Pregunta	Nota del Juez	Ruta del Switch
P1	¿Tienen auriculares bluetooth en stock?	5/5	**ACEPTADO**
P2	¿Dónde está mi pedido #12345?	4/5	**ACEPTADO**
P3	Quiero devolver un producto que me llegó roto	5/5	**RECHAZADO** (regla dura)
P4	¿Cuánto sale el iPhone 13 renovado?	4/5	**ACEPTADO**
P5	Hola, necesito ayuda	5/5	**ACEPTADO**

El código manda sobre el LLM. En P3 (devolución de un producto roto) el Juez calificó 5/5, pero la respuesta menciona el proceso de reembolso: la regla dura la pasó a ESCALAR (en esa corrida se registró como RECHAZADO) y se escaló a Slack. Es el comportamiento buscado: una promesa de dinero siempre la decide una persona, aunque esté bien redactada. En la ejecución de verificación de las capturas 3 y 4 el Juez dio 3/5 y la regla dura la escaló igual.

Bloque 2 · Matriz A/B de 10 corridas 20 %

Protocolo. Las mismas 5 preguntas se ejecutaron en dos arquitecturas: **A** (Router → Worker → salida directa, sin Juez) y **B** (Router → Worker → Juez → Switch → salida). Cada corrida registra nota, ruta, tokens por componente y costo. La nota de A la asignó la autora según lo que esperaba de la respuesta; la de B la calcula el Juez con la rúbrica.

P	Pregunta	Tipo de consulta
P1	¿Tienen auriculares bluetooth en stock?	Catálogo (RAG)
P2	¿Dónde está mi pedido #12345?	Tracking
P3	Quiero devolver un producto que me llegó roto	Devolución / escalamiento
P4	¿Cuánto sale el iPhone 13 renovado?	Catálogo (precio)
P5	Hola, necesito ayuda	Saludo / consulta general

Arq.	P	Nota	Evalúa	Ruta / estado	Router	Worker*	Juez	Total tokens	Costo US$
A	P1	5	Humano	salida directa	904	4.549	0	**5.453**	0,0055
A	P2	5	Humano	salida directa	879	4.762	0	**5.641**	0,0056
A	P3	5	Humano	salida directa	943	4.598	0	**5.541**	0,0055
A	P4	5	Humano	salida directa	999	4.298	0	**5.297**	0,0053
A	P5	5	Humano	salida directa	1.013	4.432	0	**5.445**	0,0054
B	P1	5	Juez	**ACEPTADO**	950	4.525	5.934	**11.409**	0,0114
B	P2	4	Juez	**ACEPTADO**	977	5.442	6.112	**12.531**	0,0125
B	P3	5	Juez	**RECHAZADO**	947	4.769	5.759	**11.475**	0,0115
B	P4	4	Juez	**ACEPTADO**	976	5.050	5.758	**11.784**	0,0118
B	P5	5	Juez	**ACEPTADO**	984	5.142	5.670	**11.796**	0,0118
A · prom.		**5,0**			948	4.528	0	**5.475**	**0,0055**
B · prom.		**4,6**			967	4.986	5.847	**11.799**	**0,0118**

* Worker = tokens del flujo base menos el Router (LLM Chain u otros nodos de la ruta). En B2, B4 y B5 el total de n8n incluye 739, 719 y 739 tokens que la planilla no desglosa; se usó el total reportado. Costo con la tarifa de la planilla: US$ 0,001 por cada 1.000 tokens.

Contraste: precisión vs. costo

	A · sin Juez	B · con Juez	Diferencia
Precisión promedio (1-5)	5,0 (criterio humano)	4,6 (rúbrica)	-0,4
Respuestas con nota < 5	0 de 5	2 de 5 (P2, P4)	+2
Respuestas escaladas a una persona	0 de 5	1 de 5 (P3)	+1
Tokens por ejecución (prom.)	5.475	11.799	×2,15
Costo por ejecución	US$ 0,0055	US$ 0,0118	+115 %

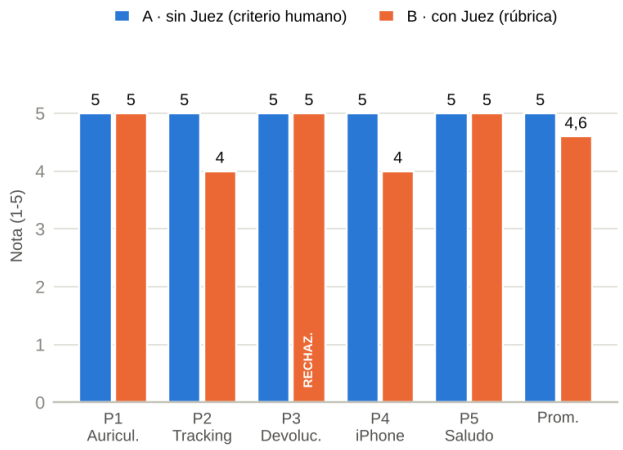
- **Precisión.** Los Workers respondieron igual en ambas arquitecturas; lo que cambia es la mirada que los evalúa. El Juez fue más estricto que la autora (4,6 contra 5,0): puntuó 4 en P2 y P4 y frenó P3. No mejoró las respuestas (la ruta CORREGIR no se activó): las audita y bloquea las riesgosas.
- **Costo.** El Juez aporta en promedio 5.847 tokens por ejecución, el 50 % del total de B, porque recibe el contexto completo del RAG además de su rúbrica. El costo se multiplica por 2,15.
- **Lectura conjunta.** En estas pruebas pagar el doble compra una garantía concreta (la respuesta con promesa de reembolso no salió sola), no una mejora de calidad medible en las demás respuestas.

Bloque 3 · Dashboard y proyección

20 %

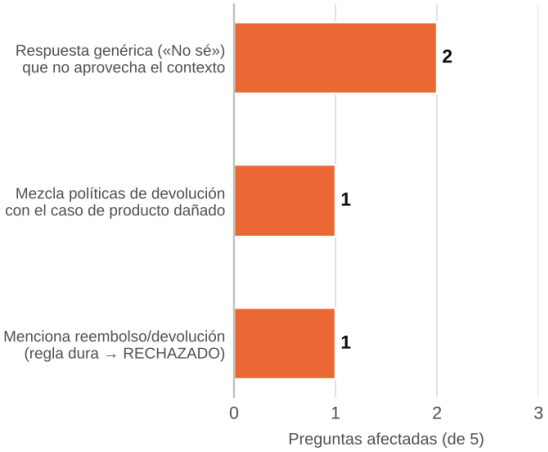
Precisión A · sin Juez	Precisión B · con Juez	Tokens por ejecución	Escaladas a una persona
5,0 / 5	**4,6 / 5**	**×2,15**	**1 de 5**
criterio humano	rúbrica del Juez	5.475 → 11.799	P3 · regla dura de dinero

Precisión promedio y por pregunta



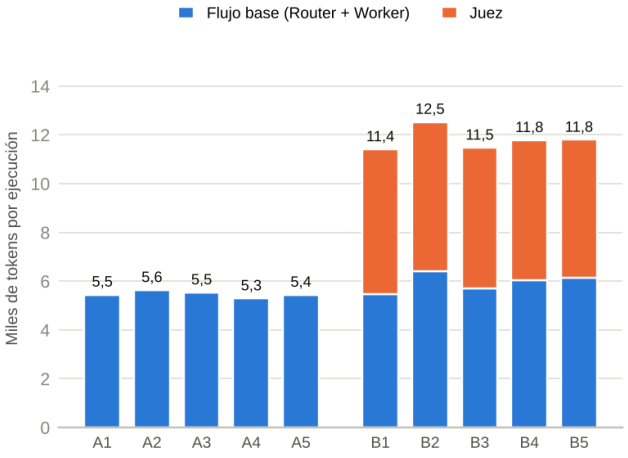
A 5,0 vs. B 4,6: el Juez puntuó 4 en P2 y P4; en P3 la nota 5 no evitó el escalamiento.

Categorías de error más frecuentes



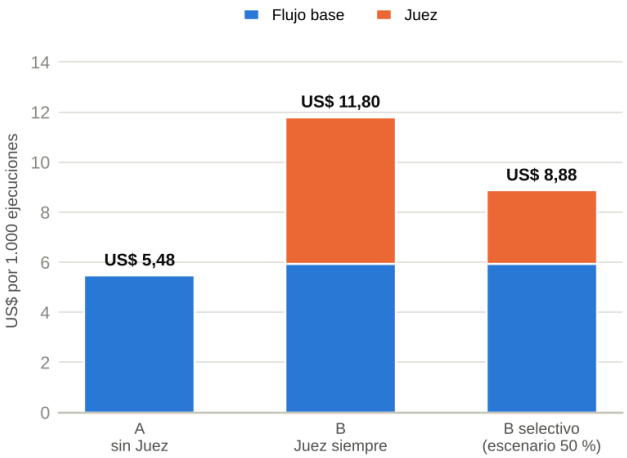
Lo más repetido: el «No sé» genérico que no aprovecha lo que el contexto permitía aclarar.

Tokens por corrida



El Juez (naranja) agrega ~5.847 tokens: casi lo mismo que todo el flujo base.

Costo proyectado a 1.000 ejecuciones



US$ 5,48 sin Juez vs. US$ 11,80 con Juez; el escenario selectivo es un supuesto, no una medición.

Proyección a 1.000 ejecuciones

Escenario	Tokens por ejecución	Costo por ejecución	Costo por 1.000 ejecuciones	Vs. A
A · sin Juez	5.475	US$ 0,0055	**US$ 5,48**	—
B · Juez en todas las ejecuciones	11.799	US$ 0,0118	**US$ 11,80**	+115 %
B selectivo · Juez en el 50 % del tráfico (supuesto)	8.876	US$ 0,0089	**US$ 8,88**	+62 %

Cálculo: tokens promedio × US$ 0,001 por cada 1.000 tokens × 1.000. El escenario selectivo suma el flujo base de B (5.952 tokens) más la mitad del costo promedio del Juez (5.847 tokens). Un Juez selectivo cuesta 25 % menos que auditar todo.

Errores más frecuentes (detalle)

Categoría	Frec.	Preguntas	Qué marcó el Juez
Respuesta genérica que no aprovecha el contexto	2	P1, P4	El Worker contestó «No sé» cuando el contexto permitía aclarar que la tienda solo vende lentes de sol Ray-Ban y no auriculares ni iPhone.
Mezcla de políticas que confunde	1	P3	Aplicó las condiciones de devolución estándar (producto sin abrir) a un producto que llegó roto, que la FAQ trata como caso aparte.
Menciona reembolso / devolución (regla dura)	1	P3	Escalado a Slack aunque la nota fue 5/5: una promesa de dinero siempre la decide una persona.

Fuente: campos `errores` y `justificacion` del Juez. Los textos de P1, P3 (mezcla de políticas) y P4 corresponden a la primera tanda con estas 5 preguntas, donde las tres puntuaron 4; en la tanda final P1 y P3 puntuaron 5 (P3 escalada por regla dura) y P4 volvió a puntuar 4. P2 puntuó 4 en la tanda final sin motivo exportado y no entra en el conteo.

Recomendación comercial

Activar el Juez en producción de forma selectiva: obligatorio en las intenciones con riesgo económico o reputacional (devoluciones y escalamiento, pedidos, precios), omitido en saludos y despedidas, y con la regla dura de dinero siempre encendida.

Por qué. Auditar todo duplica el costo (US$ 5,48 → US$ 11,80 por 1.000 ejecuciones) y en las pruebas no reescribió ninguna respuesta, pero sí frenó la única que prometía un reembolso (P3) y puntuó por debajo de 5 en 2 de 5. El riesgo está concentrado en pocas intenciones: auditar solo la mitad del tráfico (escenario) baja el costo a ≈ US$ 8,88 por 1.000 (25 % menos) sin sacar el control de donde está el riesgo. Antes de definir el porcentaje real conviene medirlo con el tráfico de producción.

Notas para leer los datos

- **Muestra y evaluadores.** 5 preguntas por arquitectura son ilustrativas, no estadísticas; la nota de A es criterio humano y la de B es la rúbrica del Juez.
- **Variabilidad del Juez.** Entre una primera tanda y la final la nota cambió en 3 de 5 preguntas (±1 punto) aun con temperatura 0; por eso se decide con umbrales y reglas duras, no con la nota como medida exacta. La ruta CORREGIR no se activó en las 5 pruebas finales.
- **Costo.** Tarifa plana de la planilla; el precio real distingue tokens de entrada y de salida. El contexto del RAG trae cada fragmento repetido: deduplicarlo bajaría los tokens del Worker y del Juez.