Plan de Gobernanza, Gestión y Monitoreo Financiero de IA

Agente de Atención al Cliente de Renovadas

Ingrid Ledesma

Coderhouse

Automatización IA

Carolina Lemes y Juan Carlos Videla Cavalcante

13 de octubre de 2026

Plan de Gobernanza, Gestión y Monitoreo Financiero de IA

Este documento presenta el plan de gobernanza, gestión y monitoreo financiero del agente de atención al cliente de Renovadas, construido sobre la arquitectura de supervisor y Juez entregada en el Módulo 8. El plan se organiza en tres dimensiones: planificación financiera y economía del token, logs estructurados y trazabilidad, gobernanza ética, ciberseguridad y compliance.

El sistema es un agente de atención al cliente de Renovadas. Su arquitectura combina un Router con Workers especializados, un Juez (AI-as-a-Judge) y un esquema de Human-in-the-loop. El stack tecnológico está compuesto por n8n (orquestación), Groq con el modelo gpt-oss-120b (inferencia), Pinecone (RAG), Airtable (auditoría y memoria), Slack (notificaciones) y HubSpot (CRM).

Dimensión 1. Planificación Financiera y Economía del Token

1.1. KPIs de negocio

Se definen tres indicadores clave de rendimiento operativos que permiten a la dirección evaluar el impacto del agente automático en el negocio de Renovadas (ver Tabla 1 y Tabla 2).

Tabla 1

Indicadores clave de rendimiento (KPIs) del agente

KPI	Valor actual	Meta
Tasa de resolución autónoma	92 %	>= 80 %
Tiempo medio de respuesta	< 10 s	< 30 seg.
Errores financieros sin supervisión	0 %	0 %

Tabla 2

Definición y medición de cada KPI

KPI	Definición	Medición	Meta
Tasa de resolución autónoma	Porcentaje de consultas que el agente resuelve sin intervención humana (ruta ACEPTADO del Switch).	Registros en Airtable (Veredictos_Juez) con estado = ACEPTADO / total de ejecuciones.	>= 80 %
Tiempo medio de respuesta	Segundos desde que llega el mensaje del cliente hasta que se envía la respuesta.	Diferencia entre timestamp de entrada (Gmail/Chat trigger) y timestamp de respuesta.	< 30 seg.
Errores financieros sin supervisión	Respuestas que prometen dinero (reembolso, devolución, descuento) y salen al cliente sin pasar por un humano.	Registros con Regla_dura no vacío y estado distinto de ESCALAR. Debe ser siempre 0.	0 %

Evidencia del Módulo 8: en las 5 pruebas de la arquitectura B, 4 de 5 fueron ACEPTADO (80 %), 1 fue ESCALAR por regla dura de dinero (P3). El KPI de errores financieros sin supervisión fue 0 %: la regla dura frenó la respuesta aunque el Juez la calificó 5/5.

1.2. Cálculo de ROI contra baseline manual

El baseline representa el costo de resolver las mismas consultas de forma manual con una operadora de atención al cliente. El sueldo promedio de referencia en Argentina (julio 2026) es de ARS 1.052.657/mes bruto, equivalente a ~ARS 5.980/hora (176 hs/mes) o ~US$ 3,87/hora al tipo de cambio oficial de octubre 2026, ARS 1.545/USD (fuente: Bumeran). En la Tabla 3 se detalla el costo manual evitado por tarea y en la Tabla 4 el resumen del ROI.

Tabla 3

Cálculo de horas manuales evitadas y costo evitado por tarea

Tarea automatizada	Tiempo manual (min/consulta)	Consultas estimadas/mes	Horas manuales evitadas/mes	Costo manual evitado (US$)
Consulta de catálogo / precio	5	400	33,3	128,87
Tracking de pedidos	10	300	50,0	193,50
Devoluciones / problemas	15	100	25,0	96,75
Saludos / consultas generales	3	200	10,0	38,70
Total		**1.000**	**118,3**	**457,82**

Además del costo directo, el agente resuelve un problema crítico del baseline: al ser Ingrid la única operadora, en horarios de alta demanda los clientes no recibían respuesta inmediata y dejaban de contestar (oportunidades perdidas). El agente responde 24/7 en menos de 10 segundos.

Tabla 4

Resumen del retorno de inversión (ROI) mensual y anual

Concepto	Valor mensual	Valor anual
Costo manual evitado (A)	US$ 457,82	US$ 5.493,84
Costo del agente con Juez a 1.000 ejecuciones (B)	US$ 11,80	US$ 141,60
Infraestructura: VPS Hostinger KVM 2 (C)	US$ 33,83	US$ 405,96
Ahorro neto mensual (A - B - C)	**US$ 412,19**	**US$ 4.946,28**
ROI	**~903 %**	(ahorro / costo) x 100

El ROI se calcula como (US$ 412,19 / US$ 45,63) x 100 = **~903 %**. El agente se paga en poco más de 3 días de operación.

1.3. Matriz de Costo Total de Operación (TCO)

La Tabla 5 detalla el presupuesto mensual de tokens e infraestructura, basado en los datos reales medidos en el Checkpoint 8 y proyectados a 1.000 ejecuciones mensuales.

Tabla 5

Matriz de Costo Total de Operación (TCO) mensual a 1.000 ejecuciones

Componente	Tokens por ejecución	Costo unitario	Costo mensual (1.000 ejec.)	% del total
Router (AI Agent clasificador)	967	US$ 0,001/1K tok	US$ 0,97	2,1 %
Workers (LLM Chain + RAG)	4.986	US$ 0,001/1K tok	US$ 4,99	10,9 %
Juez (Groq gpt-oss-120b)	5.847	US$ 0,001/1K tok	US$ 5,85	12,8 %
Subtotal tokens	**11.799**		**US$ 11,80**	**25,9 %**
VPS Hostinger KVM 2 + Easypanel (aloja n8n + su DB)	—	ARS 52.000/mes	US$ 33,83	74,1 %
Airtable (auditor. + memoria)	—	plan gratuito	US$ 0,00	0 %
Pinecone (base vectorial)	—	plan gratuito/Starter	US$ 0,00	0 %
Slack (notificaciones)	—	plan gratuito	US$ 0,00	0 %
HubSpot (CRM)	—	plan gratuito	US$ 0,00	0 %
Groq (API inference)	—	incluido en tokens	US$ 0,00	0 %
TOTAL TCO MENSUAL			**US$ 45,63**	**100 %**

El VPS Hostinger KVM 2 (2 vCPU, 8 GB RAM, 100 GB NVMe) cuesta ARS 52.000/mes, convertidos a US$ 33,83 al dólar MEP de $1.537 del 14 de octubre de 2026 (fuentes: El Cronista y Hostinger). Es el costo de bolsillo real del servidor que mantiene n8n corriendo 24/7.

Nota sobre el costo de tokens: actualmente el agente opera sobre el plan gratuito de Groq, por lo que el gasto real en tokens hoy es US$ 0. No obstante, este plan financiero proyecta el costo a precio de mercado (US$ 0,001/1K tokens) porque el plan gratuito tiene límites de rate (solicitudes por minuto y por día) que no son sostenibles para un tráfico productivo de 1.000 ejecuciones/mes. Presupuestar el tier pago es la práctica correcta de planificación. Además, el valor unitario usado es conservador (más alto que el pricing real de Groq para gpt-oss-120b), por lo que el ROI proyectado funciona como piso, no como techo.

Evolución del TCO: el VPS KVM 2 (8 GB de RAM) tiene capacidad ociosa suficiente para absorber servicios adicionales sin aumentar el costo de infraestructura. Cuando se migre la persistencia de Airtable a una base de datos PostgreSQL, esta se self-hostea en el mismo VPS: el costo de infra se mantiene en US$ 33,83/mes (solo se le da más carga al servidor ya existente), evitando el gasto de una base de datos administrada externa.

1.3.1. Optimización con Prompt Caching

El system prompt del Juez (rúbrica completa, ~800 tokens) y el contexto fijo del RAG (manuales de Renovadas, ~2.000 tokens por fragmento) son bloques masivos que se repiten en cada ejecución. Si se migra el Juez a la API de Anthropic (Claude), el Prompt Caching permite cachear estos bloques fijos y pagar solo el 10 % del costo de los tokens cacheados en las llamadas subsiguientes. Con Groq, el contexto de la rúbrica viaja completo en cada llamada; la optimización actual se basa en acotar el contexto del RAG (deduplicar fragmentos repetidos de Pinecone) y mantener la rúbrica concisa.

1.4. Control preventivo de API Keys

Los entornos de desarrollo y producción se separan físicamente mediante API Keys distintas, con límites de gasto estrictos (ver Tabla 6).

Tabla 6

Control preventivo de API Keys por entorno

Entorno	API Key	Límite mensual	Propósito
Desarrollo / pruebas	GROQ_API_KEY_DEV	US$ 5/mes	Pruebas en n8n, ajustes de rúbrica. Límite bajo para neutralizar bucles lógicos accidentales.
Producción	GROQ_API_KEY_PROD	US$ 10/mes	Tráfico real de clientes. Monitoreado con alertas.
Pinecone	PINECONE_API_KEY	Plan gratuito (100K vectores)	Base vectorial de conocimiento (FAQ, políticas). Sin costo adicional.

Separación física: las llaves de desarrollo y producción son API Keys distintas generadas en la consola de Groq. En n8n, cada entorno usa su propia credencial. El límite de US$ 5/mes en desarrollo garantiza que un bucle lógico infinito (por ejemplo, un Worker que se llama a sí mismo) no genere un gasto inesperado: Groq corta las llamadas al alcanzar el tope y el flujo falla con un error controlado en vez de seguir consumiendo tokens.

Dimensión 2. Logs Estructurados y Trazabilidad (traceId)

2.1. Dashboard operativo (Airtable, Veredictos_Juez)

El dashboard operativo se alimenta de forma nativa desde n8n hacia Airtable (tabla Veredictos_Juez). Cada ejecución del flujo registra automáticamente el veredicto del Juez con los campos que se describen en la Tabla 7, incluyendo el traceId agregado para este módulo.

Tabla 7

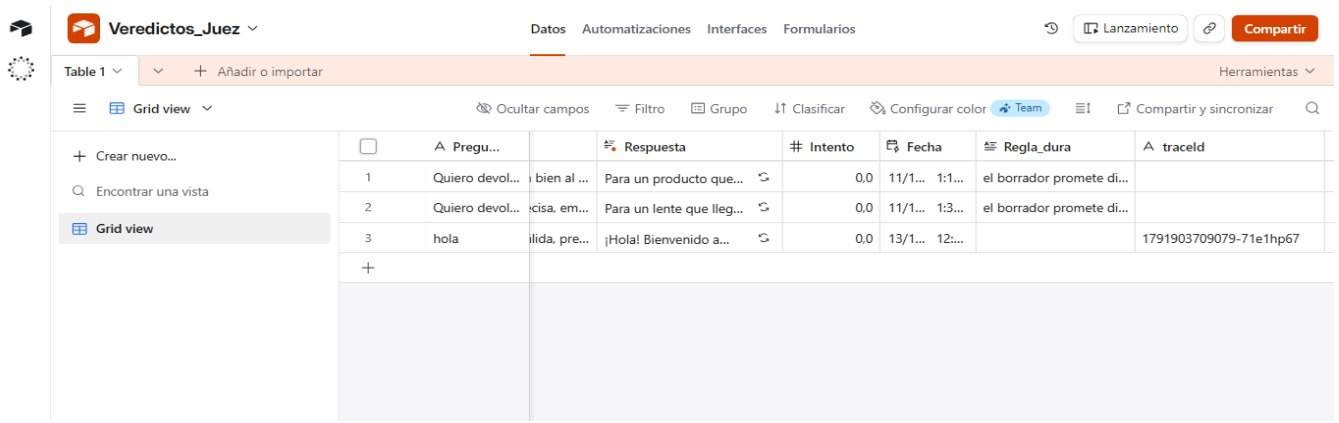
Campos del dashboard operativo en Airtable (tabla Veredictos_Juez)

Campo en Airtable	Tipo	Descripción	Ejemplo
Pregunta	Long text	Pregunta original del cliente	Quiero devolver un producto que me llegó roto
Puntaje	Number	Nota del Juez (1-5)	3
estado	Single select	Estado final del Switch (ACEPTADO / CORREGIR / ESCALAR)	ESCALAR
Errores	Long text	Lista de errores detectados por el Juez	Afirmar que los envíos dañados son una excepción...
Justificación	Long text	Justificación del puntaje en 1-2 frases	La respuesta deriva bien al email...
Respuesta	Long text	Respuesta propuesta por el Worker	Para un producto que llegó dañado, contactá...
Intento	Number	Número de intento (0 = primera vez, 1 = reintento)	0
Fecha	Date	Timestamp de la ejecución	13/10/2026 12:00
Regla_dura	Single line text	Motivo de regla dura (vacío si no aplica)	el borrador promete dinero al cliente
traceId	**Single line text**	**Identificador único de la ejecución (timestamp + hash aleatorio). Nuevo en M9.**	**1791903709079-71e1hp67**

Evidencia: la columna traceId fue implementada en n8n y se verifica en Airtable con el registro de prueba (traceId = 1791903709079-71e1hp67, pregunta = 'hola'), como muestra la Figura 1.

Figura 1

Tabla Veredictos_Juez en Airtable con la columna traceId implementada



Nota. el registro 3 corresponde al traceId 1791903709079-71e1hp67.

2.2. Esquema de logs máquina-procesables (JSON)

Se define el siguiente esquema JSON para auditorías operativas. Cada entrada del log representa una ejecución completa del flujo y contiene los cinco campos clave indicados en la consigna. La Tabla 8 describe cada campo.

```
{
  "traceId": "1791903709079-71e1hp67",
  "timestamp": "2026-10-13T12:03:00-03:00",
  "nodeName": "Juez_Renovadas",
  "toolOutput": {
    "errores": ["Afirmar que los envíos dañados son una excepción..."],
    "justificacion": "La respuesta deriva bien al email...",
    "exactitud_factual": 3,
    "estado_veredicto": "ESCALAR"
  },
  "systemPromptSnapshot": "Sos el Juez de calidad de Renovadas...",
  "confidenceScore": 3,
  "session_id": "021ec...",
  "regla_dura": "el borrador promete dinero al cliente"
}
```

Tabla 8

Campos del esquema de logs JSON correlacionados

Campo	Tipo	Descripción
traceId	string	Identificador único de la ejecución. Se genera al inicio del flujo (nodo Set post-Payload unificado) como timestamp en milisegundos + hash aleatorio. Viaja por toda la cadena.
timestamp	string (ISO 8601)	Momento exacto en que se procesó el nodo. Permite reconstruir la línea de tiempo de la ejecución.
nodeName	string	Nombre del nodo de n8n que generó esta entrada (Router, Worker_Catalogo, Juez_Renovadas, etc.).
toolOutput	object	Salida estructurada del nodo. Para el Juez: errores, justificación, exactitud_factual y estado_veredicto.
systemPromptSnapshot	string (truncado)	Primeros 100 caracteres del system prompt activo. Permite auditar qué versión de la rúbrica se usó.
confidenceScore	integer (1-5)	Puntaje de confianza de la IA. En este agente, coincide con exactitud_factual del Juez.

2.3. Recorrido del traceId por el flujo

El traceId se genera una sola vez y viaja por toda la cadena de nodos sin modificarse, permitiendo correlacionar todos los pasos de una misma ejecución (ver Tabla 9).

Tabla 9

Recorrido del traceId por el flujo de n8n

Paso	Nodo en n8n	Acción con traceId
1	Payload unificado (Merge)	Unifica la entrada de Gmail y Chat. El traceId aún no existe.
2	Set (post-Payload unificado)	GENERA el traceId: String($now.toMillis()) + '-' + Math.random().toString(36).substring(2,10)
3	Lectura Airtable + Contexto	El traceId viaja como campo del JSON. No se modifica.
4	AI Agent (Router)	Clasifica la intención. El traceId viaja en el payload.
5	Workers especializados	Cada Worker (Catálogo, Tracking, etc.) recibe y pasa el traceId.
6	Respuesta de workers (convergencia)	Normaliza campos. El traceId sigue en el JSON.
7	Execute Workflow (Juez_Renovadas)	El traceId se pasa al sub-workflow como parte del JSON de entrada.

Paso	Nodo en n8n	Acción con traceId
8	Log veredicto Juez (Airtable)	Se GRABA el traceId en la tabla Veredictos_Juez como campo de texto.
9	Guardar resumen comprimido (Airtable)	Se GRABA el traceId también en la tabla de conversaciones.

Auditoría retroactiva: con el traceId, un auditor puede filtrar en Airtable por un ID específico y ver qué preguntó el cliente, qué respondió el Worker, qué nota le puso el Juez, qué errores detectó, si se aplicó una regla dura y si se escaló a Slack. Todo en una sola búsqueda.

Dimensión 3. Gobernanza Ética, Ciberseguridad y Compliance

3.1. Mapa de riesgos y controles configurados

Se identifican los principales riesgos éticos y de ciberseguridad del agente y los controles no-code implementados en el flujo para mitigarlos (ver Tabla 10).

Tabla 10

Mapa de riesgos éticos y de ciberseguridad y sus controles

#	Riesgo	Control configurado	Dónde está en el flujo
1	**Alucinación: el agente inventa datos** (precios, estados de pedido, plazos que no están en el contexto del RAG).	El Juez evalúa Exactitud Factual con descuento de -2 puntos si inventa datos. Si la nota baja a 1-2 o el Juez emite RECHAZADO, el Switch escala a un humano.	Sub-workflow Juez_Renovadas (criterio 1 de la rúbrica) + nodo Umbrales (código) + Switch (ruta ESCALAR).
2	**Promesa financiera no autorizada:** el agente promete reembolsos, devoluciones o descuentos sin autorización.	Regla dura en código: una regex detecta palabras clave (reembolso, devolución, crédito a favor, descuento no presente en el contexto) y fuerza ESCALAR independientemente de la nota del Juez.	Nodo de código 'Umbrales' (variable prometeDinero). Evidencia: P3 fue escalada con nota 5/5.
3	**Prompt Injection:** un cliente inyecta instrucciones en su mensaje para alterar el comportamiento del agente.	El system prompt del Juez y los Workers incluyen instrucciones explícitas de rol. La temperatura está fijada en 0 para minimizar creatividad. El Juez recibe el contexto y la respuesta	System Message del nodo Juez_Renovadas (temperatura 0, Structured Output Parser que fuerza JSON válido).

#	Riesgo	Control configurado	Dónde está en el flujo
		como datos, no como instrucciones.	
4	**Sesgo algorítmico:** el agente favorece o discrimina a ciertos clientes por el tipo de consulta.	La rúbrica del Juez exige objetividad institucional: los mismos 4 criterios se aplican a toda consulta. El Juez no tiene información sobre el cliente. Los umbrales son fijos en código, no en el LLM.	Rúbrica en el system prompt del Juez (4 criterios con descuento fijo) + umbrales hardcodeados en el nodo Umbrales.
5	**Bucle lógico infinito:** un error en el flujo causa que un nodo se llame a sí mismo indefinidamente, consumiendo tokens sin control.	El máximo de reintentos del Juez está fijado en 1: si el Worker corregido vuelve a obtener nota 3, se escala a un humano. Las API Keys de desarrollo tienen límite de US$ 5/mes.	Nodo Umbrales (condición intento >= 1 fuerza ESCALAR) + límites de gasto en Groq Console.

3.2. Gobernanza de datos y privacidad empresarial

Se documenta la política de cada proveedor de LLM e infraestructura respecto al uso de datos corporativos para entrenamiento de modelos (ver Tabla 11).

Tabla 11

Gobernanza de datos y privacidad por proveedor

Proveedor	Política de datos	Configuración recomendada	Dónde se verifica	Área responsable
Groq (LLM inference)	Por defecto, Groq no retiene datos de clientes para inferencia. El Data Processing Addendum prohíbe usar datos de clientes para entrenar modelos. Ofrece Zero Data Retention (ZDR) como opción.	Activar ZDR en Console > Settings > Data Controls. Esto desactiva incluso el log de troubleshooting de 30 días.	console.groq.com/settings/data-controls	Sistemas / Legal
Pinecone (base vectorial)	Almacena solo los vectores y metadatos que el usuario indexa. No usa datos de clientes para entrenar modelos. Los datos se almacenan en la	Configurar el índice en la región adecuada (ej: us-east-1). Revisar que no se indexe información sensible en los metadatos.	Pinecone Console > Index > Settings	Sistemas

Proveedor	Política de datos	Configuración recomendada	Dónde se verifica	Área responsable
	región configurada.			
Airtable (auditor. + CRM)	Los datos de las tablas son propiedad del usuario. Airtable no usa datos de tablas para entrenar modelos de IA. Airtable AI es una función separada con opt-in.	No habilitar Airtable AI en las tablas con datos de clientes. Usar el plan Team o Enterprise para control de acceso granular.	airtable.com/account > Privacy settings	Sistemas / Legal
n8n (orquestador)	Self-hosted en Easypanel: los datos del flujo permanecen en el servidor propio. n8n no tiene acceso a los datos que procesan los workflows.	Mantener la instancia self-hosted. No migrar a n8n Cloud si se requiere control total de datos.	Panel de Easypanel (VPS propio)	Sistemas

Para un despliegue real: antes de poner el agente en producción con datos reales de clientes, el área de Legal debería revisar el DPA (Data Processing Addendum) de Groq y verificar que la configuración ZDR cumple con la normativa aplicable (por ejemplo, la Ley 25.326 de Protección de Datos Personales en Argentina). El área de Sistemas debería verificar que ZDR está activo en la consola de Groq y que las API Keys de producción están bajo la cuenta corporativa con la configuración adecuada. No es necesario contactar a ninguna área para esta entrega.

Conclusión

Este plan estructura la gestión operativa del agente de atención al cliente de Renovadas en tres dimensiones. La economía del token muestra un ROI superior al 900 % con un TCO de US$ 45,63/mes para 1.000 ejecuciones, incluyendo el VPS Hostinger que aloja n8n las 24 horas. La trazabilidad queda garantizada por el traceId que recorre toda la cadena y se graba en Airtable. La gobernanza ética se apoya en los controles ya implementados en el Módulo 8 (Juez, reglas duras y umbrales en código), complementados con la política de Zero Data Retention de Groq. El sistema está listo para escalar a producción con los controles documentados en este plan.

Fuentes consultadas

Bumeran: salarios de atención al cliente en Argentina (julio 2026).

El Cronista: cotización del dólar MEP (14 de octubre de 2026).

Hostinger: planes y precios de VPS (plan KVM 2).

Groq: política de datos y Zero Data Retention (ZDR).

Pinecone, Airtable y n8n: documentación de seguridad y privacidad.